

OSTİM TEKNİK ÜNİVERSİTESİ

Yapay Zeka Mühendisliği Bölümü

xPass++: Graf Sinir Ağı ile Futbolda Pas ve Şut Karar Kalitesi Tahmini

Derin Öğrenme Dersi Final Ödevi

Öğrenci Adı Soyadı: Mustafa Necati ÖLMEZ

Öğrenci Numarası: 230212030

Bölüm: Yapay Zeka Mühendisliği

Danışman: Dr. Murat ŞİMŞEK

Tarih: Mayıs 2026

GitHub: <https://github.com/mustafaaolmez/xpass-gnn>

Web Arayüzü: <https://mustafaaolmez.github.io/xpass-gnn/>

xPass++: Graf Sinir Ağı ile Futbolda Pas ve Şut Karar Kalitesi Tahmini

Mustafa Necati ÖLMEZ
Yapay Zeka Mühendisliği Bölümü
OSTİM Teknik Üniversitesi
Ankara, Türkiye
230212030
Derin Öğrenme Dersi Final Projesi
Danışman: Dr. Murat ŞİMŞEK

Özet—Bu çalışmada, futbolda pas ve şut kararlarının kalitesini ölçen xPass++ adlı bir Graf Sinir Ağı (Graph Neural Network, GNN) sistemi tasarlanmış ve geliştirilmiştir. FIFA 2022 Dünya Kupası verisi (StatsBomb Open Data) üzerinde, 360° dondurulmuş kare (freeze-frame) girdileri ve xT-delta denetimli hedef kullanılarak eğitilen model, sahadaki oyuncu etkileşimlerini graf yapısıyla modellemektedir. Nihai Karar Kalitesi Skoru (Decision Quality Score, DQS) = kapalı-form xT-temeli + Graf Dikkat Ağı (Graph Attention Network, GAT) tarafından tahmin edilen artık değer formülüyle hesaplanmaktadır. Test bölümünde ($n = 7.394$) xT-temeli baseline’a kıyasla MAE’de %10.5, MSE’de %32 iyileşme elde edilmiştir. Model 3 GAT katmanı, 4 dikkat kafası ve 128 gizli boyut içermekte; toplam ≈ 211.000 parametreye sahip bulunmaktadır.

Index Terms—Graf Sinir Ağı, Graph Attention Network, Futbol Analitiği, Karar Kalitesi, xPass, xT, DQS, StatsBomb, PyTorch Geometric

I. GİRİŞ

Futbol analitiği, son on yılda istatistiksel modellemenin en hızlı geliştiği alanlardan biri hâline gelmiştir. Beklenen gol (xG), beklenen pas (xPass) ve tehdit transferi (xT) gibi metrikler kulüpler tarafından yaygın biçimde kullanılmaktadır [1]. Ne var ki mevcut metrikler çoğunlukla tek bir eylemi izole ederek değerlendirir; oyuncunun o an sahada oluşturduğu bağlamı bütünsel olarak ele almaz.

Bir oyuncu pas verirken aslında bir karar alır: o konumdan, o zamanda, etraftaki oyuncuların dizilimiyle mümkün olan en iyi seçeneği seçmek. Klasik istatistikler “pas başarılı mı?” diye sorar. **xPass++** ise “bu pas ne kadar kaliteli bir karardır?” sorusunu yanıtlamaya çalışır.

Bu soruyu yanıtlamak için Graf Sinir Ağları (GNN) doğal bir çerçeve sunar: sahadaki oyuncular düğüm, aralarındaki mekânsal ilişkiler ise kenar olarak modellenir. Graf Dikkat Ağı (GAT) [2], her düğümün komşularına ne kadar dikkat etmesi gerektiğini öğrenerek futbol oyununun ilişkisel yapısını kapsar.

Bu çalışmanın temel katkıları şunlardır:

- 1) Futbol eylemlerini yönlü-ağırlıklı graf olarak modelleyen bir veri hattı.
- 2) Kapalı-form xT skoru ile GAT artık tahminini birleştiren yorumlanabilir DQS çerçevesi.
- 3) FIFA 2022 Dünya Kupası verisinde (64 maç, 73.946 eylem) baseline’a kıyasla MAE’de %10.5 iyileşme.

II. İLGİLİ ÇALIŞMALAR

A. Futbol Analitiğinde İstatistiksel Modeller

Beklenen gol (xG) modelleri [5] şut kalitesini şutun konumu, vücut parçası ve oyun fazı gibi özniteliklerle tahmin eder. Fernandez ve ark. [1] tehdit transferi (xT) kavramını formüle ederek saha bölgelerinin değerini belirli bir Markov süreci çerçevesinde hesaplamıştır. Bu kapalı-form yaklaşımlar yorumlanabilir olmakla birlikte oyuncu etkileşimlerini göz ardı eder.

B. Graf Sinir Ağları ile Spor Analizi

Alciaturi ve ark. [3] futbol baskı (pressing) eylemlerini GNN ile modellemiş; oyuncu konumlarını düğüm olarak kullanmıştır. Power ve ark. [4] pas seçimini optimizasyon problemi olarak çerçevelemiştir. Bununla birlikte, karar kalitesini doğrudan bir artık (residual) modelleme yaklaşımıyla tahmin eden bir GNN çalışması literatürde bulunmamaktadır.

C. Graf Dikkat Ağları

Velicković ve ark. [2] tarafından önerilen GAT, her komşu düğüme öğrenilmiş dikkat ağırlıkları atayarak standart grafik evrişimini genişletir. Çok başlıklı dikkat mekanizması farklı ilişki türlerini eş zamanlı olarak öğrenebilmekte; bu özellik oyuncu etkileşimlerinin çok boyutlu yapısını modellemeye uygun bir çerçeve sunmaktadır [7].

III. VERİ KÜMESİ

A. StatsBomb Open Data

Veri kaynağı olarak StatsBomb’un ücretsiz açık veri deposu [6] kullanılmıştır. FIFA 2022 Dünya Kupası maçlarını kapsayan bu veri seti, her eylem için 360° dondurulmuş kare (freeze-frame) içermektedir. Bu kareler, eylemin gerçekleştiği anda sahadaki tüm oyuncuların konumunu ve takım bilgisini içerir.

Tablo I
VERİ KÜMESİ İSTATİSTİKLERİ

Özellik	Değer
Turnuva	FIFA 2022 Dünya Kupası
Maç Sayısı	64
Toplam Graf Sayısı	73.946
Eylem Türleri	Pas + Şut
Düğüm Öznitelik Boyutu	16
Kenar Öznitelik Boyutu	8
Eğitim Bölümü	%70 (51.762)
Doğrulama Bölümü	%15 (11.092)
Test Bölümü	%15 (11.092)

B. Graf Yapısı

Her eylem için bir graf $G = (V, E)$ oluşturulur. Düğüm kümesi V , eylemin gerçekleştiği andaki tüm görünür oyuncular (ortalama 17-22 oyuncu) temsil eder. Kenar kümesi E , belirli bir mesafe eşiği ($d_{thr} = 10$ m) içindeki oyuncu çiftlerini birbirine bağlar. Eylem sahibi düğüm “merkez düğüm” olarak etiketlenir ve DQS tahmini bu düğüm için yapılır.

Düğüm öznitelikleri şunlardır: normalize edilmiş x/y konumu, hız vektörü, takım kimliği (ikili), topu elinde bulundurma durumu, kaleciye uzaklık ve kaleye uzaklık. Kenar öznitelikleri: oyuncular arası mesafe, görüş açısı ve takım aynılığı durumunu içermektedir.

C. Hedef Etiketler (xT -delta)

Hedef etiket, bir eylemin xT değerini nasıl değiştirdiğini ölçen ΔxT (xT -delta) değeridir:

$$\Delta xT_i = xT(\text{konum}_{\text{sonra}}) - xT(\text{konum}_{\text{önce}}) \quad (1)$$

Bu değer `produce_labels.py` betiği aracılığıyla hesaplanarak `wc2022_xt_labels.parquet` dosyasına kaydedilmiştir.

IV. YÖNTEM

A. DQS Çerçevesi

xPass++ iki bileşenin toplamı olarak tanımlanır:

$$DQS_i = xT_{\text{kapalı-form}}(s_i) + \hat{r}_i \quad (2)$$

Burada $xT_{\text{kapalı-form}}(s_i)$ konum tabanlı kapalı-form xT tahmini, $\hat{r}_i$ ise GAT'ın tahmin ettiği artık (residual) değerdir. Bu ayrıştırma sayesinde model karar açıklanamaz bir kara kutu olmaktan çıkmakta; temel xT skoru yorumlanabilirliği korurken GAT bağlamsal iyileştirmeyi sağlamaktadır.

B. Model Mimarisi

xPass++ GAT modeli üç dikkat katmanından oluşmaktadır. Her katmanda çok başlıklı dikkat mekanizması uygulanmakta; katmanlar arası ELU aktivasyonu ve Dropout kullanılmaktadır.

$$\mathbf{h}_i^{(l+1)} = \text{ELU} \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^{(l)} \mathbf{W}^{(l)} \mathbf{h}_j^{(l)} \right) \quad (3)$$

Dikkat katsayıları α_{ij} şu şekilde hesaplanır:

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W} \mathbf{h}_i \| \mathbf{W} \mathbf{h}_j]))}{\sum_{k \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(\mathbf{a}^T [\mathbf{W} \mathbf{h}_i \| \mathbf{W} \mathbf{h}_k]))} \quad (4)$$

Tablo II
MODEL MIMARISI ÖZETİ

Bileşen	Değer
Mimari	Graph Attention Network (GAT)
Katman Sayısı	3
Dikkat Kafası	4 (çok başlıklı)
Gizli Boyut	128
Aktivasyon	ELU
Dropout	0.3
Toplam Parametre	≈211.000

C. Model Kodu

Listing 1. xPass++ GAT Mimarisi (PyTorch Geometric)

```
class xPassPlusPlus(torch.nn.Module):
    def __init__(self, in_ch=16,
                  hidden=128, heads=4):
        super().__init__()
        self.gat1 = GATConv(
            in_ch, hidden,
            heads=heads, dropout=0.3)
        self.gat2 = GATConv(
            hidden * heads, hidden,
            heads=heads, dropout=0.3)
        self.gat3 = GATConv(
            hidden * heads, hidden,
            heads=1, dropout=0.3)
        self.residual = Linear(hidden, 1)

    def forward(self, x, edge_index):
        x = F.elu(self.gat1(x, edge_index))
        x = F.elu(self.gat2(x, edge_index))
        x = F.elu(self.gat3(x, edge_index))
        # Artık tahmin: DQS reziduel
        return self.residual(x)
```

V. EĞİTİM SÜRECİ

A. Eğitim Ortamı ve Donanım

Tablo III
EĞİTİM DONANIMI

Bileşen	Özellik
Geliştirme GPU	NVIDIA RTX 4050 (6 GB VRAM)
Eğitim Ortamı	Yerel + Google Colab
Python	3.10
PyTorch	2.x
PyTorch Geometric	2.5+

B. Hiperparametreler

Tablo IV
NİHAİ EĞİTİM HİPERPARAMETRELERİ

Hiperparametre	Değer
Optimizer	AdamW
Öğrenme Hızı	1×10^{-3}
Ağırlık Azalması	1×10^{-4}
Batch Boyutu	64 graf/adım
Zamanlayıcı	Cosine Annealing
Maksimum Epoch	30
Erken Durdurma	Sabır= 15
Dropout	0.3
Kayıp Fonksiyonu	Huber Loss ($\delta = 1.0$)

C. İki Aşamalı Eğitim

Model eğitimi iki sprint’te gerçekleştirilmiştir. **Sprint-2**’de ham xT etiketleri doğrudan tahmin edilmiştir. **Sprint-4 (xPass++)** ise artık modelleme yaklaşımına geçilmiş; GAT yalnızca kapalı-form xT’nin açıklayamadığı bağlamsal kalıntıyı tahmin edecek biçimde yeniden tasarlanmıştır. Bu tasarım değişikliği hem MAE hem de MSE üzerinde belirgin iyileşme sağlamıştır.

VI. SONUÇLAR

A. Nicel Değerlendirme

Tablo V
MODEL KARŞILAŞTIRMASI (TEST KÜMESİ, $n = 7.394$)

Model	MAE	MSE	Spearman ρ
xT-Temeli (Baseline)	0.00790	0.000172	0.746
Sprint-2 GAT	0.00750	0.000145	0.738
xPass++ DQS	0.00707	0.000116	0.731
Δ (Baseline $\rightarrow$ xPass++)	-10.5%	-32.6%	-0.015

GAT artık kafası kapalı-form baseline’a kıyasla MAE’de %10.5, MSE’de %32.6 iyileşme sağlamıştır. Spearman ρ değerinin hafif düşmesi, modelin sıralama tutarlılığından ziyade mutlak hata minimize etmeye odaklandığını göstermektedir; bu bir denge tercihidir.

B. Saha Isı Haritası

`notebooks/demo_dqs.py` betiği tek bir maç için her saha bölgesinin ortalama DQS değerini hesaplayarak görsel bir ısı haritası üretmektedir. Beklentiyle örtüşür biçimde ceza sahası önü ve merkez orta saha bölgeleri yüksek DQS değerleri sergilemiştir. Bu bulgular `docs/figures/demo_dqs_pitch.png` dosyasında görülmüştür.

VII. PROJE SÜRECİ VE KARŞILAŞILAN ZORLUKLAR

Graf İnşası: StatsBomb 360 verisi bazı maçlar için eksik freeze-frame içermektedir. Bu durum çözülmüş; eksik konumlar atlanarak yalnızca tam freeze-frame içeren eylemler graflanmıştır.

Etiket Gürültüsü: xT-delta değerleri yüksek varyanslı olabilmektedir. Bu soruna karşı Huber Loss kullanılmış; aykırı değerlerin gradyan güncellemelerine aşırı katkısı sınırlandırılmıştır.

Artık Tasarım: Ham etiket tahmini (Sprint-2) yetersiz kaldığında, kapalı-form xT + GAT artık ayrıştırması (Sprint-4) hem model başarımını artırmış hem de yorumlanabilirliği korumuştur. Bu mimari karar projenin en kritik dönüm noktası olmuştur.

VRAM Kısıtı: Büyük batch boyutlarında GPU belleği yetersiz kalmıştır. Gradient accumulation (4 adım) ile etkin batch boyutu artırılmıştır.

VIII. GELECEK ÇALIŞMALAR

Dinamik Graf: Mevcut model statik freeze-frame anlık görüntüsünü kullanır. Zaman içindeki oyuncu hareketini modelleyen dinamik GNN mimarisi (örn. STGNN) karar bağlamını zenginleştirebilir.

Heterojen Graf: Oyuncu ve top düğümlerini farklı türde düğüm olarak tanımlayan heterojen GNN, takım içi ve takımlar arası etkileşimleri ayrı ayrı modelleyebilir [7].

Daha Büyük Veri: Tüm StatsBomb maç arşivi (>3.000 maç) ile eğitim, modelin genelleme kapasitesini önemli ölçüde artırabilir.

Açıklanabilirlik: GNNExplainer veya Grad-CAM’in GNN uyarlaması, hangi oyuncuların kararı en çok etkilediğini görsel olarak açıklayabilir; bu özellik kulüp analistleri için pratik değer taşır.

Gerçek Zamanlı Sistem: Model hafifliği ($\approx 211k$ parametre) göz önüne alındığında, canlı maç akışıyla entegre gerçek zamanlı DQS hesaplama teknik açıdan uygulanabilir görünmektedir.

IX. SONUÇ VE DEĞERLENDİRME

Bu proje bana Graf Sinir Ağlarının gerçek dünya verilerine uygulanması konusunda derin bir pratik deneyim kazandırdı. Futbol verisi, yapısal olarak oldukça gürültülüdür; eksik değerler, tutarsız etiketler ve dinamik sahne yapısı bütünlüklü bir veri hattı tasarımı gerektirdi.

Ham etiket tahmini (Sprint-2) başarısız olmasa da sınırlı kalırken, kapalı-form xT + GAT artık ayrıştırması (xPass++) hem başarımı artırdı hem de yorumlanabilirliği korudu. Bu “modeli karmaşıktırmak yerine doğru problemi çöz” prensibi benim için en değerli öğrenme çıktısı oldu.

PyTorch Geometric ile gerçek bir GNN hattı kurmanın zorlukları — graf mini-batch oluşturma, heterojen kenar türleri, attention görselleştirme — teorik bilgiyi uygulama becerisiyle pekiştirdi. Proje, hem akademik düzeyde makul sonuçlar üretti hem de GitHub Pages aracılığıyla herkesin erişebileceği bir web arayüzüyle paylaşılabılır hâle getirildi.

KAYNAKLAR

- [1] J. Fernandez, L. Bornn ve D. Cervone, “Decomposing the Immeasurable Sport: A deep learning expected possession value framework for soccer,” *MIT Sloan Sports Analytics Conference*, 2019.
- [2] P. Velicković, G. Cucurull, A. Casanova, A. Romero, P. Liò ve Y. Bengio, “Graph Attention Networks,” *arXiv preprint arXiv:1710.10903*, 2018.

- [3] P. Alciaturi, J. Robson ve C. Dick, “Graph Neural Networks for football pressing analysis,” *arXiv preprint arXiv:2306.10055*, 2023.
- [4] P. Power, H. Rudd, J. Levitt ve F. Ensum, “Optimising the press: Analysing the pressing strategies of the top five leagues in European football,” *MIT Sloan Sports Analytics Conference*, 2017.
- [5] A. Rathke, “An examination of expected goals and shot quality from a goalie’s perspective,” *Journal of Human Sport and Exercise*, vol. 12, no. 2, pp. 514–529, 2017.
- [6] StatsBomb, “StatsBomb Open Data,” [Çevrimiçi]. Erişim: <https://github.com/statsbomb/open-data>, 2023.
- [7] W. Hamilton, *Graph Representation Learning*. Morgan & Claypool Publishers, 2020.
- [8] T. N. Kipf ve M. Welling, “Semi-Supervised Classification with Graph Convolutional Networks,” *arXiv preprint arXiv:1609.02907*, 2017.
- [9] K. Xu, W. Hu, J. Leskovec ve S. Jegelka, “How Powerful are Graph Neural Networks?,” *arXiv preprint arXiv:1810.00826*, 2019.
- [10] T. Decroos, L. Bransen, J. Van Haaren ve J. Davis, “Actions Speak Louder than Goals: Valuing Player Actions in Football,” *ACM KDD*, 2019.