

xPass++: Graf Sinir Ağı ile Futbolda Karar Kalitesi Skoru

Proje Analiz ve Teknik Değerlendirme Raporu

Mustafa Necati ÖLMEZ
Yapay Zeka Mühendisliği (3. Sınıf)
OSTİM Teknik Üniversitesi

Ders Sorumlusuna Not: Proje kodları ve ilgili tüm dokümantasyon GitHub üzerinden iletilmiştir. Çalışmanın akademik temelini destekleyen DeepLearning.AI sertifikası rapor ekinde yer almaktadır.

1 Yönetici Özeti

Bu çalışmada, modern futbolun en kritik aşamalarından biri olan "karar kalitesi" problemini derin öğrenme yöntemleriyle ele aldım. Geliştirdiğim **xPass++** modeli, 2022 FIFA Dünya Kupası'ndaki 73.946 aksiyonu birer grafik yapısı olarak işleyerek, geleneksel istatistiklerin (xG, xT) göremediği "anlık saha dizilimi" avantajını skora dahil etmektedir.

2 Problemin Tanımı

Futbolda bir pasın başarısı genellikle "topun yerine ulaşp ulaşmadığı" ile ölçülür. Ancak bu, pası veren oyuncunun o anki diğer seçeneklerini ve risk/ödül dengesini açıklamaz. Geleneksel modeller sadece koordinat verisine odaklanırken, ben bu projede tüm oyuncuların konumlarını bir Graf Dikkat Ağı (GAT) ile işleyerek, her kararın kalitesini sayısal bir değere dönüştürmeyi hedefledim.

3 Veri Seti ve Ön İşleme

Analizlerimde StatsBomb Open Data üzerinden FIFA 2022 Dünya Kupası verilerini kullandım.

- Veri Kapsamı:** 64 maç, 123.773 aksiyon.
- Graf Yapısı:** Her oyuncu bir düğüm (12 boyutlu özellik), aralarındaki mesafe ve yönler ise kenar (4 boyutlu özellik) olarak tanımlanmıştır.
- Bölümleme:** Maç bazlı %80 eğitim, %10 doğrulama ve %10 test.

4 Model Mimarisi

Projeyi Velickovic vd. (2018) tarafından önerilen **Graf Dikkat Ağı (GAT)** mimarisi üzerine kurdum.

- Dikkat Mekanizması:** Sahadaki kritik oyuncular (pas yollarını kapatan savunmacılar vb.) otomatik olarak ağırlıklandırılır.
- Katmanlar:** 3 ardışık GAT katmanı ve global ortalama havuzlama (Global Mean Pooling).
- Parametre:** ~210.945 eğitilebilir ağırlık.

5 Artık Kafa (Residual) Çözümü

Geliştirme sürecinin en kritik aşaması Sprint-4'teki mimari değişikliğidir. İlk denemelerde modelin "az uyum" (underfit) sorunu yaşadığını fark ettim. Çözüm olarak, modelin tüm skoru sıfırdan tahmin etmesi yerine, sadece $xT_{baseline}$ formülünün hata payını (artık değerini) öğrenmesini sağladım.

Formül:

$$DQS = xT_{baseline} + GAT_{artik}$$

6 Performans Analizi

Yapılan iyileştirmeler sonucunda model, temel matematiksel formüllere kıyasla hata payını ciddi oranda düşürmüştür.

Tablo 1: Model Karşılaştırması

Model	MAE	MSE
xT-Temeli	0.00790	0.000172
GAT (Ham)	0.03125	0.002679
gray!10 xPass++	0.00707	0.000116

7 Sonuç ve Çıkarımlar

Nihai modelimiz (xPass++), MAE'de %10.5 ve MSE'de %32 oranında iyileşme sağlamıştır. Bu, grafik ağlarının anlık saha dizilimini anlamada standart ızgara tabanlı modellere göre daha başarılı olduğunu kanıtlamaktadır.

8 Teknik Kurulum Adımları

Projeyi yerel ortamda çalıştırmak için aşağıdaki komut dizisi takip edilmelidir:

```
# Sanal ortam ve kurulum
python -m venv .venv
source .venv/bin/activate
pip install torch==2.11.0
pip install -r requirements.txt

# Çalıştırma
python scripts/download_data.py
python -m src.train_residual
```